ONNX·TensorRT Day 5

탐지 모델 TensorRT · 종합 프로젝트 : 위험구역 침입 감지

HYUNDAI AI Insight Campus · 온디바이스 AI · ONNX·TensorRT 5/5

2026. 11. 10 (화) 09:00–18:00 · 8교시 · Google Colab (T4 GPU 필수)

TRTInfer | YOLOv8n | AP | 4 stages | intrusion | 발표

강사 : 김정인 · 김구수

오늘의 학습 목표

5 일의 마지막 계단 — 엔진을 실제 파이프라인에 넣는다

1 TRTInfer

빌드 · 실행 함수를 클래스로 — __init__ 에서 준비 , __call__ 에서 실행

2 YOLOv8n 엔진

FP16 엔진 + VB 전처리 (letterbox) · 후처리 (decode · NMS) 연결

3 정확도

Penn-Fudan 170 장으로 ORT · TRT FP32 · FP16 의 AP 비교

4 네 조각 시간

전처리 · 추론 · 후처리 · 그리기 — 추론이 빨라진 뒤의 병목

5 침입 감지 이식

추론기만 교체 → 결과 영상 · 이벤트 CSV · 최종 성능표

6 발표 · 종합

3 분 발표 · 5 일 종합 퀴즈 30 문항 · 다음 과목 연결

시간표

8 교시 × 50 분 · 점심 12:00–13:00 · 5~6 교시 미니 프로젝트 · 7 교시 발표 · 8 교시 종합 퀴즈

교시	시간	주제	형태	애니메이션
1	09:00–09:50	Day 4 복습 퀴즈 · 함수 → 클래스 TRTInfer	퀴즈 + 실습	D5-1 함수 → 클래스
2	10:00–10:50	YOLOv8n 엔진 · VB 전처리 · 후처리 연결	강의 + 실습	D5-2 YOLO 입출력
3	11:00–11:50	정확도 확인 — ORT vs TRT FP32 vs FP16 AP	강의 + 실습	D5-3 AP 비교
4	13:00–13:50	시간 나눠 재기 — 전처리 · 추론 · 후처리 · 그리기	강의 + 실습	D5-4 네 조각
5	14:00–14:50	미니 프로젝트 ① 이식 — 추론기만 교체	개인 실습	D5-5 한 곳만 교체
6	15:00–15:50	미니 프로젝트 ② 영상 · 이벤트 · 성능표 · 채점	개인 실습	D5-6 이벤트
7	16:00–16:50	팀 발표 3 분 (과제 5)	발표	D5-7 발표 구성
8	17:00–17:50	5 일 종합 퀴즈 30 문항 · 제출 · 다음 과목	퀴즈 + 정리	D5-8 5 일 지도

오늘의 자료 · 온라인 링크

예측 (애니메이션) → 확인 (노트북) → 점검 (워크시트)

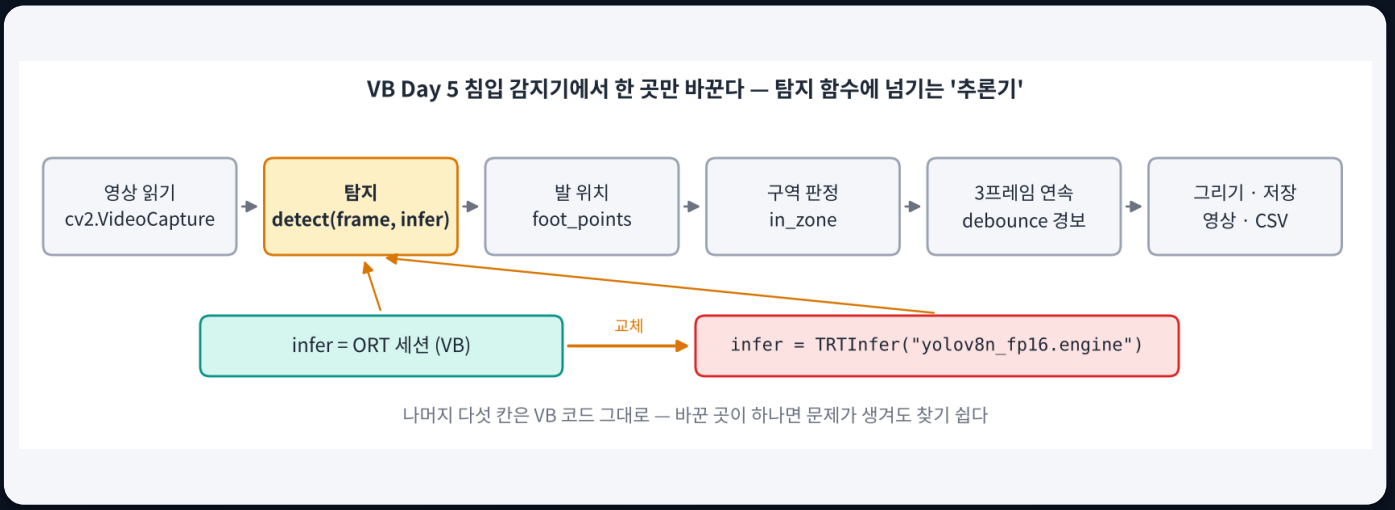
기본 주소 (Day 5)

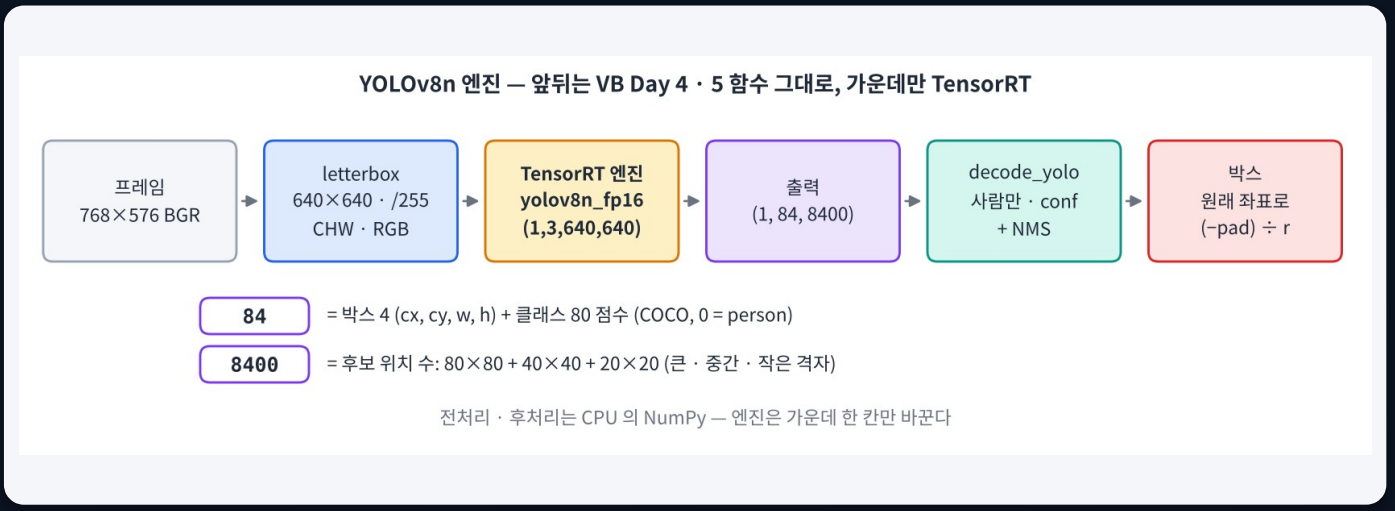
https://imguru-mooc.github.io/AI_CAMPUS/OT-day5/

animation.html	애니메이션 8 개 (D5-1 ~ D5-8) — #d5-1 처럼 바로가기
worksheet.html	개념 워크시트 — #t1 ~ #t8 교시 바로가기 (교시당 10 문항)
OT_Day5_lecture.ipynb	강의 노트북 — 1~4 교시 문제 + 미니 프로젝트 과제 1~5 + 제출
data/	yolov8n.onnx · people.mp4 (VB 와 같은 파일) · Penn-Fudan 은 데이터 셀이 받음
Day 4 복습 퀴즈	1 교시 09:00 — Google Forms 20 문항
5 일 종합 퀴즈	8 교시 17:00 — Google Forms 30 문항 (Day 1~5)
trt_ 이름 .zip	제출 — 성능표 · 이벤트 CSV · 프레임 로그 · 결과 영상 + 노트북

오늘의 큰 그림 — 한 곳만 바꾼다

VB Day 5 침입 감지기의 추론기만 TensorRT 로 · 나머지는 그대로





오늘의 데이터 · 확인된 숫자 (CPU)

yolov8n.onnx — 2 교시

노드 233 · (1,3,640,640) → (1,84,8400)

Penn-Fudan — 3 교시

170 장 · 423 명 · ORT CPU AP50 0.968

people.mp4 — 5–6 교시

768×576 · 10 FPS · 795 프레임

ORT CPU 추론 — 4 교시

약 75 ms / 프레임 (실행 예 · 2 코어)

TensorRT 숫자 — 전체

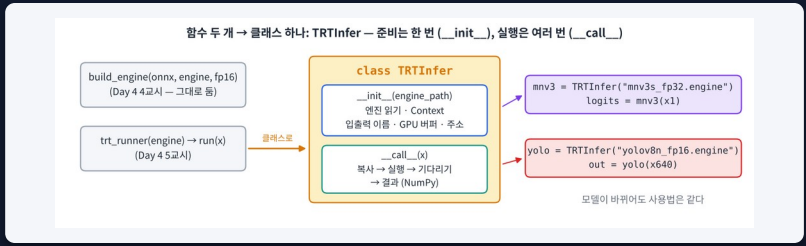
Colab T4 에서 각자 확인

1 Day 4 복습 · 함수 → 클래스 TRTInfer

09:00–09:50

학습 목표

- Day 4 복습 퀴즈 20 문항 (15 분)
- __init__ : 엔진 · Context · 버퍼 (한 번)
- __call__ : 복사 → 실행 → 기다리기
- build_once — 있으면 건너뜀



노트북 실습

1. 복습 퀴즈 (Google Forms)
2. 문제 1-1 TRTInfer 완성
3. 문제 1-2 mnv3s 로 확인

▶ 애니메이션 D5-1 함수 → 클래스

핵심 개념

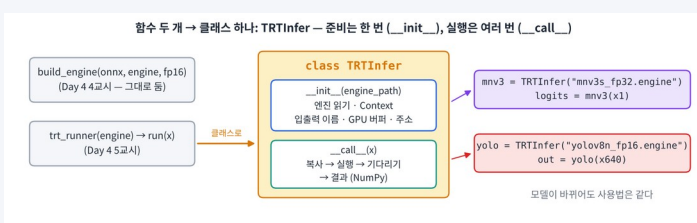
준비

```
self.buf = {n: torch.empty(shape, device="cuda")
            for n in names}
for n in names:
    self.context.set_tensor_address(
        n, self.buf[n].data_ptr())
```

실행

```
def __call__(self, x):
    self.buf[self.inputs[0]].copy_(...)
    self.context.execute_async_v3(stream)
    torch.cuda.synchronize()
    return self.buf[self.outputs[0]].cpu().numpy()
```

클래스



체크포인트

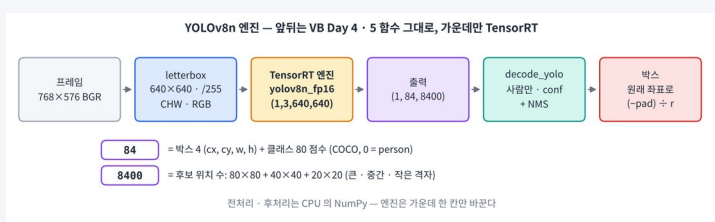
__call__ 이 있으면 객체를 함수처럼 부른다 — ORT 세션 함수와 바꿔 끼울 수 있다.

2 YOLOv8n 엔진 · VB 함수 연결

10:00–10:50

학습 목표

- yolov8n.onnx → FP16 엔진 (수 분)
- (1,3,640,640) → (1,84,8400)
- letterbox · decode_yolo 그대로
- detect(frame, infer)



노트북 실습

1. 문제 2-1 FP16 엔진 · 입출력
2. 문제 2-2 detect · ORT 와 비교

▶ 애니메이션 D5-2 YOLOv8n 입출력

핵심 개념

탐지

```
def detect(frame, infer, conf=0.25):
    lb, r, (pl, pt) = letterbox(frame)
    x = (lb[..., ::-1].transpose(2, 0, 1)[None]
         / 255.0).astype(np.float32)
    boxes, s = decode_yolo(infer(x), conf)
    return (boxes - [pl, pt, pl, pt]) / r, s
```

비교

```
detect(frame200, ort_infer)   # ORT CPU 7 명
detect(frame200, yolo16)      # TRT FP16
```

입출력



체크포인트

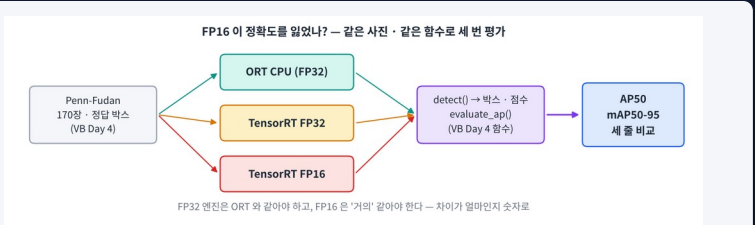
infer 를 인자로 — ORT · TRT FP32 · FP16 어느 것이든 같은 detect.

3 정확도 확인 — AP 비교

11:00–11:50

학습 목표

- Penn-Fudan 170 장 · 정답 박스
  - 같은 detect · 같은 evaluate_ap
- AP 는 conf 0.01 로
  - 박스 단위 짝 IoU



노트북 실습

1. 문제 3-1 세 실행기 AP 표
2. 문제 3-2 FP16 vs FP32 짝 IoU

▶ 애니메이션 D5-3 FP16 정확도 — AP 비교

핵심 개념

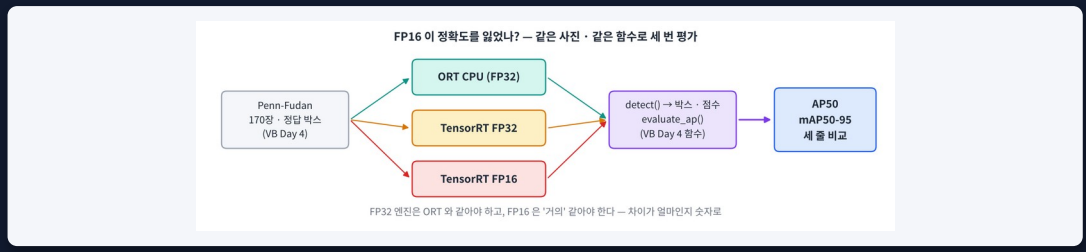
AP 표

```
runtime    AP50   mAP50-95
ORT CPU    0.968  0.834   ← CPU 실행 예
TRT FP32   ≈ ORT
TRT FP16   ≈ ORT  (Colab 에서 확인)
```

짝 IoU

```
iou_matrix(b16, b32).max(1)
# 평균 · 0.95 이상 비율로 판단
```

평가



체크포인트

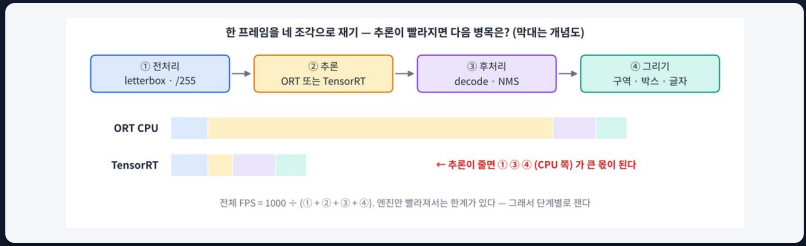
FP32 엔진 = ORT, FP16 ≈ ORT — 차이를 '느낌' 이 아니라 AP 숫자로.

4 시간 나눠 재기 — 네 조각

13:00–13:50

학습 목표

- 전처리 · 추론 · 후처리 · 그리기
- FPS = 1000 ÷ 네 조각의 합
- 추론 ↓ → CPU 쪽이 병목
- 다음 개선 : GPU 전처리 · NMS



노트북 실습

1. 문제 4-1 time_stages · 50 프레임
2. 문제 4-2 비율 · 누적 막대

▶ 애니메이션 D5-4 네 조각 · 다음 병목

핵심 개념

ORT CPU

```
pre 3.5 · infer 75 · post 1.4 · draw 0.8 ms
# 실행 예 · CPU 2 코어 → 추론이 93%
```

TensorRT

```
infer 가 크게 줄면
pre · post · draw 의 비중이 커진다
# 실제 비율은 Colab T4 에서
```

네 조각



체크포인트

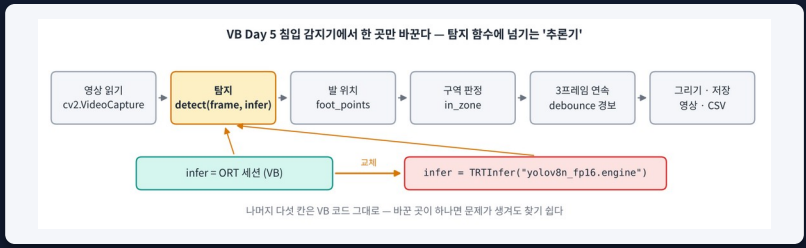
엔진만 빨라져서는 한계 — 단계별로 재야 다음에 고칠 곳이 보인다 .

5 미니 프로젝트 ① 이식

14:00–14:50

학습 목표

- 바꾸는 곳 = infer 하나
- 발 위치 · 구역 · debounce 그대로
- 3 프레임 연속 → 경보
- source 는 한 곳 (나중에 카메라)



노트북 실습

1. 과제 1 process_frame (20)
2. 과제 2 run_intrusion (20)

▶ 애니메이션 D5-5 추론기만 교체

핵심 개념

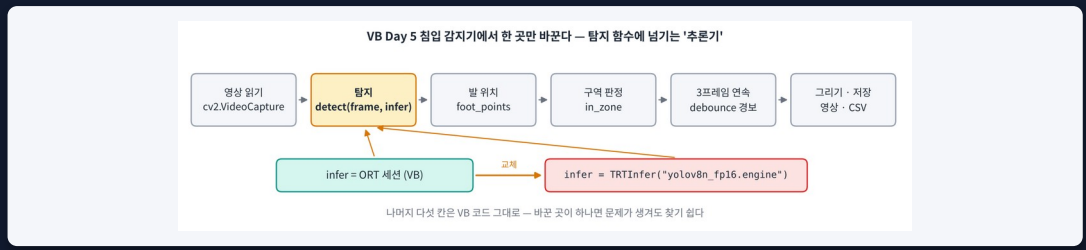
한 프레임

```
boxes, _ = detect(frame, infer)
inside = [in_zone(p) for p in foot_points(boxes)]
streak = streak + 1 if any(inside) else 0
alarm = int(streak >= n_consec)
```

영상

```
log_trt = run_intrusion(VIDEO,
    "intrusion_trt.mp4", yolo16)
# 795 프레임 · 결과 영상 · 프레임 로그 CSV
```

교체



체크포인트

바꾼 곳이 하나면 문제가 생겨도 찾기 쉽다 — 이식의 원칙 .

6 미니 프로젝트 ② 결과 만들기

15:00–15:50

학습 목표

- 결과 영상 (H.264) 재생
- find_events → 이벤트 CSV
- 추론만 vs 파이프라인 전체
- ot_baseline.csv 최종본



노트북 실습

1. 과제 3 이벤트 요약 (20)
2. 과제 4 성능 비교 (20)
3. 채점 셀 (80 점)

▶ 애니메이션 D5-6 debounce · 이벤트

핵심 개념

이벤트

```
find_events([0, 1, 1, 0, 1], 10)
# → [(0.1, 0.2), (0.4, 0.4)]
# ORT 기준 실행 예 : 경보 221 프레임 · 5 번
```

성능표

```
model                  provider  precision
yolov8n ( 추론만 )     ORT CPU · TRT FP32 · FP16
intrusion pipeline     ORT CPU · TRT FP16
```

결과물



체크포인트

파이프라인 FPS 가 영상 FPS (10) 보다 크면 실시간으로 따라간다 .

7 팀 발표 3 분 (과제 5)

16:00–16:50

학습 목표

- 결과 영상 — 경보 장면 하나
- 최종 성능표 — 조건과 함께
- 가장 오래 걸린 단계 · 다음 개선
- 다른 팀에 질문 하나씩



노트북 실습

1. 발표 준비 10 분
2. 팀별 3 분 + 질문
3. 과제 5 강사 채점 (20)

▶ 애니메이션 D5-7 발표 3 분 구성

핵심 개념

채점

```
숫자 + 조건      5
FP16 정확도 근거    5
병목 · 다음 개선    5
질문에 대한 답      5
```

좋은 문장

```
'Colab T4 · 배치 1 · 640 입력 · 795 프레임 평균
 파이프라인 n FPS, FP16 AP50 차이 0.00x'
```

세 장면



체크포인트

숫자는 반드시 조건과 함께 : 장치 · 실행기 · 정밀도 · 몇 프레임 평균 .

8 5 일 종합 퀴즈 · 제출 · 다음 과목

17:00–17:50

학습 목표

- 종합 퀴즈 30 문항 (Day 1~5)
- trt_ 이름 .zip + 노트북 제출
- 5 일 계단 다시 보기
- 다음 과목 : INT8 · 현장 안전 · YOLO Edge



노트북 실습

1. 종합 퀴즈 25 분
2. 제출 파일 만들기
3. 5 일 정리

▶ 애니메이션 D5-8 5 일 지도 · 다음 과목

핵심 개념

5 일

```
Day 1 export · ORT    Day 2 그래프 · opset
Day 3 bench · 옵션  Day 4 엔진 · FP16
Day 5 TRTInfer · 침입 감지
```

다음

```
Quantization·Pruning (11/16~)  INT8
현장 안전 프로젝트 (11/25~)    source → 카메라
YOLOv8 Edge (12/11~)           직접 학습한 YOLO
```

5 일 지도



체크포인트

Jetson 에는 .onnx 를 가져가 그 장치에서 엔진을 다시 빌드한다 .

오늘의 핵심 정리

각 항목 옆 번호는 다시 볼 애니메이션

TRTInfer	__init__ 준비 (한 번) · __call__ 실행 — 모델이 바뀌어도 사용법은 같다	D5-1
YOLOv8n	(1,3,640,640) → (1,84,8400) · letterbox · decode_yolo 그대로	D5-2
detect	detect(frame, infer) — infer 만 바꿔 끼운다	D5-2
정확도	같은 detect · evaluate_ap 로 AP 비교 · FP16 ≈ ORT	D5-3
네 조각	pre + infer + post + draw · 추론 ↓ 이면 CPU 쪽이 병목	D5-4
이식	process_frame · run_intrusion — 바꾼 곳은 infer 하나	D5-5
결과	영상 · 프레임 로그 · 이벤트 CSV · ot_baseline.csv	D5-6
발표	숫자는 조건과 함께 · 병목과 다음 개선	D5-7

5 일을 마치며 — 다음 과목으로

내보내기 → 열어보기 → 실행하기 → 빠르게 하기 → 파이프라인에 넣기

ONNX·TensorRT (5 일)		다음 과목
ot_baseline.csv (FP32 · FP16)	→	Quantization·Pruning — INT8 줄 추가
build_engine · TRTInfer	→	그대로 — INT8 엔진도 같은 클래스로
run_intrusion(source=VIDEO)	→	현장 안전 프로젝트 — source 를 카메라로
T4 에서 만든 엔진	→	Jetson 에서 .onnx 로 다시 빌드
yolov8n.onnx (사전학습)	→	YOLOv8 Edge — 직접 학습한 모델로
네 조각 시간 · 병목	→	GPU 전처리 · GPU NMS 로 다음 개선

5 일 동안 수고 많으셨습니다 — 노트북 · ot_baseline.csv · .onnx 를 Drive 에 저장해 두세요